

# Ocena praga za klasifikacijo med dvema motoričnima aktivnostima

Izpitna seminarska naloga pri predmetu Komunikacija človek računalnik

Bernarda Petek

2.2.2023, Ljubljana

## 1 Uvod

Človeški možgani nenehno komunicirajo s preostankom telesa. To počnejo tako, da oddajajo in sprejemajo električne signale, ki se razlikujejo glede na informacije, ki jih prenašajo. Med takšne informacije spadajo tudi realne ali pa namišljene motorične aktivnosti. V tej seminarski nalogi sem ocenjevala prag za klasifikacijo med dvema motoričnima aktivnostima na EEG signalih, ki sem jih pridobila iz podatkovne baze EEGMMI DS [1]. Svoje metode sem uporabila na večih subjektih, pri katerih sem ocenjevala prag za klasifikacijo med aktivnostima stiskanja leve in desne roke in med zamišljenima aktivnostima stiskanja leve in desne roke.

## 2 Metode

Vsak subjekt iz podatkovne baze EEGMMI DS premore 12 posnetkov EEG signalov. Vsak posnetek je sestavljen iz možganskih signalov, ki so merjeni s 64 elektrodami in imajo frekvenco 160 vzorcev na sekundo. Pri oceni praga sem se osredotočila na posamezne meniške pomembne posnetke, torej tiste, ki so predstavljali stiskanje leve in desne roke ali namišljeno stiskanje leve in desne roke. Postopek obdelave signalov je bil sledeč.

### 2.1 Segmentacija

Najprej sem signale v posameznem posnetku razdelila na intervale T0, T1, T2, kjer intervali T0 predstavljajo mirovanje, T1 pravi ali namišljen stisk leve roke in T2 pravi ali namišljen stisk desne roke. To sem storila s pomočjo funkcije `getIntervals`, podane na spletni učilnici. Ta funkcija vrača robove intervalov na katerih je subjekt miroval, realno ali namišljeno stiskal levo roko in realno ali namišljeno stiskal desno roko. Po tem, ko sem dobila robove intervalov, sem originalne signale razdelila v tri množice in sicer prva množica je predstavljala signale na intervalih T0, druga na intervalih T1 in tretja na intervalih T2.

## 2.2 Izračun in izbor SPV filtrov ter prostorsko filtriranje

Po tem, ko sem signale razdelila v tri množice signalov na določenih intervalih, sem uporabila signale na prvih intervalih iz množic T1 in T2, da sem s pomočjo funkcije  $f\_CSP[2]$ , ki je podana na spletni učilnici, pridobila transformacijsko matriko  $W$ , ki je predstavljala SPV (skupni prostorski vzorci) filtre. Koeficienti v matriki  $W$  so izračunani tako, da minimizirajo razmerje varianc dveh različnih motoričnih aktivnosti. Nato sem signale na intervalih T1 in T2 (z izjemo prvih intervalov) transformirala z matriko  $W$ . Nastali so prostorsko filtrirani signali. Za vsak interval prostorsko filtriranih signalov sem izbrala dve značilki, ki bosta kasneje predstavljali točko v 2-dimenzionalnem prostoru. Za vsak interval prostorsko filtriranih signalov je prvi signal v prostorsko filtrirani matriki predstavljal prvo značilko in zadnji (štiriinšestdeseti) signal drugo značilko. Tako sem za vsak interval z izjemo prvih v množici T1 in T2 dobila dva signala, ki sta predstavljala dve značilki.

## 2.3 Pasovni spektralni filtri

Vsak signal, ki predstavlja eno značilko, sem nato filtrirala s pasovno prepustnim KEO filtrom. Pri tem sem spreminjala dva vhodna parametra in opazovala kako se rezultati spreminjajo v odvisnosti od izbranega filtra. Parametra, ki sem ju spreminjala, sta bila pas prepuščanja filtra in koeficient natančnosti  $n$ . Pas prepuščanja filtra je zavzel vrednost 8 – 13 Hz ali pa vrednost 8 – 13Hz. Koeficient natančnosti  $n$  je zavzel vrednosti od 20 do 105 s korakom večanja 5.

## 2.4 Varianca in logaritem

Po filtriranju s KEO filtrom sem za vsak signal, ki je predstavljal značilko izračunala logaritem njegove variance. Tako sem dobila SPV značilke. Za vsak interval sem dobila dve značilki.

## 2.5 Graf raztrosa

Kot omenjeno, sem za vsak interval, ki sem ga po zgoraj opisanem postopku obdelala, dobila dve značilki. Ti dve značilki sta predstavljali absciso in ordinato točke v koordinatnem sistemu. Tako sem preslikala signale na vseh razen prvih intervalih iz množic T1 in T2 v točke v ravnini. Tako nastal diagram raztrosa je sestavljen iz dveh množic točk. Prva množica predstavlja značilke z intervalov T1 in druga množica predstavlja značilke z intervalov T2. Na danih grafih lahko v splošnem med množicama točk potegnemo premico, ki predstavlja prag za klasifikacijo med dvema motoričnima aktivnostima. Točke na eni strani premice z veliko verjetnostjo predstavljajo prvo motorično aktivnost in točke na drugi strani premice z veliko verjetnostjo predstavljajo drugo motorično aktivnost.

Zgoraj opisan postopek obdelave je implementiran v funkciji  $ocena\_praga(record, annot, st, hz)$ , ki za vhodne parametre sprejme ime subjekta v bazi  $record$ , anotacijo posnetka  $annot$ , koeficient natančnosti  $st$  in zgornjo mejo pasu prepuščanja v KEO filtru  $hz$ . Izhod funkcije je graf raztrosa. Primer uporabe funkcije je:  $ocena\_praga('eegmmidb/S020/S020R12.edf', 'event', 35, 13)$ .

### 3 Rezultati


Metodo sem preizkusila na različnih subjektih z različnimi parametri filtrov. To je vidno v skripti *testiranje\_izpit.m*. En izmed subjektov na katerem sem testirala svojo metodo je bil subjekt *S005* in posnetek *S005R12*. Metodo sem testirala s KEO filtrom na pasih prepuščanja 8 – 13Hz in 8 – 30Hz ter z vrednostmi koeficientov natančnosti 20 – 105 s korakom 5. Tako sem dobila 36 grafov raztrosa. Med temi grafi raztrosa so izstopali grafi vidni na Sliki 1. Najbolj jasna meja med namišljenim stiskanjem leve in desne roke se vidi na grafu raztrosa spodaj levo, ko je koeficient natančnosti enak 55 in meja prepuščanja 8-13Hz. Tukaj lahko potegnemo premico, ki striktno ločuje eno množico od druge. Pri ostalih grafih raztrosa se ena točka od namišljenega stiskanja leve roke nahaja na strani točk namišljenega stiskanja desne roke, a še vedno zelo blizu namišljeni premici, ki jo lahko potegnemo med množicama točk. Verjetnostno je zato prag še vedno dober.

### 4 Diskusija


Metoda, ki sem jo implementirala je v splošnem zelo dobra za določanje praga med dvema motoričnima aktivnostima. Njena učinkovitost je precej odvisna od optimalnosti izbire parametrov dolžine praga prepuščanja in koeficienta natančnosti pri KEO filtru. Smiselno bi bilo ugotoviti ali obstajajo univerzalno optimalni koeficienti.

### References


- [1] Gerwin Schalk, Dennis J McFarland, Thilo Hinterberger, Niels Birbaumer, and Jonathan R Wolpaw. Bci2000: a general-purpose brain-computer interface (bci) system. *IEEE Transactions on biomedical engineering*, 51(6):1034–1043, 2004.
- [2] Gert Pfurtscheller, Christoph Guger, and Herbert Ramoser. Eeg-based brain-computer interface using subject-specific spatial filters. In *Engineering Applications of Bio-Inspired Artificial Neural Networks: International Work-Conference on Artificial and Natural Neural Networks, IWANN'99 Alicante, Spain, June 2–4, 1999 Proceedings, Volume II 5*, pages 248–254. Springer Berlin Heidelberg, 1999.




8-30Hz, n=90



8-30Hz, n=65



8-13Hz, n=55



8-13Hz, n=40

Figure 1: Grafi raztrosa za subjekt *S005* in posnetek *S005R12*. Zgoraj je uporabljen KEO filter s prepuščanjem 8-30Hz in koeficientoma natančnosti 90(levo) in 65(desno) Spodaj je uporabljen KEO filter s prepuščanjem 8-13Hz in koeficientoma natančnosti 55(levo) in 40(desno)